

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ
по лабораторной работе №4
по дисциплине «Построение и анализ алгоритмов»
Тема: Алгоритм Кнута-Морриса-Пратта

Студентка гр. 3343

Гельман П.Е.

Преподаватель

Жангиров Т.Р.

Санкт-Петербург

2025

Цель работы.

Цель данной лабораторной работы состоит в изучении алгоритма Кнута-Морриса-Пратта и его реализации.

Задание.

Реализуйте алгоритм КМП и с его помощью для заданных шаблона P ($|P| \leq 15000$) и текста T ($|T| \leq 5000000$) найдите все вхождения P в T .

Вход:

Первая строка - P

Вторая строка - T

Выход:

индексы начал вхождений P в T , разделенных запятой, если P не входит в T , то вывести -1

Sample Input:

ab

abab

Sample Output:

0,2

Заданы две строки A ($|A| \leq 5000000$) и B ($|B| \leq 5000000$). Определить, является ли A циклическим сдвигом B (это значит, что A и B имеют одинаковую длину и A состоит из суффикса B , склеенного с префиксом B). Например, defabc является циклическим сдвигом abcdef.

Вход:

Первая строка - A

Вторая строка - B

Выход:

Если A является циклическим сдвигом B , индекс начала строки B в A иначе вывести -1 . Если возможно несколько сдвигов вывести первый индекс.

Sample Input:

defabc

abcdef

Sample Output:

3

Выполнение работы.

Алгоритм Кнута-Морриса-Пратта (КМП-алгоритм) — эффективный алгоритм, осуществляющий поиск подстроки в строке, используя то, что при возникновении несоответствия само слово содержит достаточно информации, чтобы определить, где может начаться следующее совпадение, минуя лишние проверки.

В ходе выполнения работы были реализованы следующие функции:

- `vector<int> prefixFunc(const string &Pattern)` – префиксная функция, вычисляет для каждого i -го символа строки длину наибольшего собственного префикса подстроки от первого символа до i -го, который также является её суффиксом.
- `vector<int> KMT(string P, string T)` – реализует алгоритм Кнута-Морриса-Пратта, который эффективно ищет вхождения подстроки P в строке T , используя предварительно вычисленную префикс-функцию. Сначала вычисляется префикс функция, далее сканируем текст T , сверяя символы с P . Если символы совпали – двигаемся дальше. Если несовпадение – используем $\pi[j-1]$, чтобы избежать лишних сравнений. Тем самым, мы сдвигаемся не на один символ, а на число, лежащее в $\pi[j-1]$, которое говорит, что этот набор $\pi[j-1]$ символов относительно первого несовпавшего равен этому же набору первых $\pi[j-1]$ символов, а они в свою очередь совпадают с последними $\pi[j-1]$ символами в исходном тексте до первого несовпадающего. Если дошли до конца P , значит, нашли вхождение.
- `int KMPcycle(const string& Pattern, const string& Text)` - реализует алгоритм КМП для поиска подстроки $Pattern$ в строке $Text$ с учетом циклических сдвигов. В начале работы вычисляется префикс-функция для строки $Pattern$. Далее выполняется проход

по удвоенной длине `Text`, используя индекс $i \% t_len$ для обеспечения циклического поиска. Если текущий символ строки `Text` совпадает с соответствующим символом `Pattern`, индекс j увеличивается, и поиск продолжается. В случае несовпадения выполняется откат индекса j по значениям из префикс-функции pi . Если индекс j достигает длины `Pattern`, значит, найдено полное совпадение, и функция возвращает индекс начала совпадения, который соответствует количеству циклических сдвигов. Если подстрока не найдена, функция возвращает -1 .

Оценка сложности.

1. Общая сложность алгоритма КМП по времени – $O(n+m)$, где n – количество символов в тексте, m – количество символов в подстроке. Эта оценка объясняется тем, что для нахождения значений префикс-функции требуется $O(m)$ времени; для прохода по тексту в функции КМР, чтобы найти вхождения подстроки, необходимо $O(n)$ времени. Сложность по памяти – $O(m)$, так как мы храним вектор pi длин префиксов, равный длине m подстроки.

2. Сложность алгоритма КМП для поиска циклического сдвига – $O(2*n+m)$, так как требуется в худшем случае дважды проходить по всей длине n входного текста, а также один раз по длине m подстроки для получения вектора префикс-функции. Однако, для определения циклического сдвига необходимо сравнивать текст и подстроку одинаковой длины, иначе в этом не будет смысла, соответственно алгоритм будет работать за $O(3n)$. Сложность по памяти также равна $O(m)$, объясняется хранением вектора длины m .

Тестирование.

Результаты тестирования представлены в табл. 1.

Таблица 1 – Результаты тестирования

№ п/п	Входные данные	Выходные данные	Комментарии
1.	aba abacaba	0,4	Верно
2.	ksk mvccs	Подстрока не обнаружена в тексте. [-1]	Верно
3.	aaaaaa aaaaaaaaaaaaabaaaaaaaaa a	0,1,2,3,4,5,6,7,14,15,16,17,18	Верно
4.	aba baa	Количество необходимых сдвигов - 1	Верно
5.	Flower monkey	Число в ответе больше длины исходного текста. Ошибка, ответ - -1	Верно
6.	j ddfjf	Строки разных размеров, А - не циклический сдвиг В: -1	Верно

Выводы.

В ходе лабораторной работы был реализован алгоритм Кнута-Морриса-Пратта для поиска вхождений подстроки в текст, проанализирована его временная сложность и сложность по памяти.

ПРИЛОЖЕНИЕ А

ИСХОДНЫЙ КОД ПРОГРАММЫ

Название файла: kmp.cpp

```
#include <iostream>
#include <string>
#include <vector>
#include <windows.h>

using namespace std;

vector<int> prefixFunc(const string &P) {
    cout << "    \n[ШАГ 1] Нахождение значения функции pi для строки: " << P
    << endl;
    int p_len = (int)P.size();
    vector<int> pi(p_len, 0);
    int j = 0;
    cout << "\n    pi[0] = 0 независимо от строки\n";
    for (int i = 1; i < p_len; i++) {
        cout << "\n    Анализ символа '" << P[i] << "' (позиция " << i << ")
        в шаблоне." << endl;
        while (j > 0 && P[i] != P[j]) {
            cout << "        Нашли различающиеся символы('" << P[i] <<"' -
            позиция " << i << ", '" << P[j] <<"' - позиция " << j << "), возвращаемся к
            предыдущему индексу.\n";
            j = pi[j - 1];
            cout << "        После отката j = " << j << endl;
        }
        if (P[i] == P[j]) {
            cout << "        Символы совпадают ('" << P[i] <<"' - позиция "
            << i << ", '" << P[j] <<"' - позиция " << j << "), увеличиваем индекс j
            (количество символов с текущем найденном префиксе).\n";
            j++;
            cout << "        j = " << j << endl;
        }
        cout << "        Присваиваем значение индекса j в pi[" << i << "] =
        " << j << endl;
        pi[i] = j;
    }
    cout << "    \n[РЕЗУЛЬТАТ] Префикс-функция вычислена: ";
    for (int val : pi) cout << val << " ";
    cout << endl;
    return pi;
}

vector<int> KMT(string P, string T){
    cout << "===== Алгоритм Кнута-Морриса-Пратта. =====\n";
    int t_len = (int) T.size(), p_len = (int)P.size();
    vector<int> pi = prefixFunc(P);
    vector<int> ans;
    cout << '\n';
    int j = 0;
    cout << "\n[ШАГ 2] ";
    cout << "Продолжаем алгоритм КМП. \n";
    for (int i = 0; i < t_len; i++) {
        cout << "    Итерация i = " << i << ", символ в строке поиска: " <<
        T[i % t_len] << endl;
        while (j > 0 && T[i] != P[j]) {
            cout << "\n    Найдены отличающиеся символы в строке и
            подстроке"
```

```

        "(" << T[i] <<"' - позиция " << i <<" , '" << P[j] <<"'
- позиция " << j << " , возвращаемся к индексу"
        , который лежит в pi[" << j-1 << "]\n";
        j = pi[j - 1];
        cout << "    Индекс j после отката = " << j << "\n\n";
    }
    if (T[i] == P[j]) {
        cout << "    Сравниваемые символы совпадают ('" << T[i] <<"' -
позиция " << i <<" , '" << P[j] <<"' - позиция " << j << " , производим
поиск дальше. ";
        j++;
        cout << "Текущий индекс подстроки j - " << j << endl;
    }
    if (j == p_len) {
        cout << "\n    Длина входной подстроки совпала с найденной
подстрокой, "
                "записываем индекс начала подстроки в тексте в
результат.\n";
        ans.push_back(i - p_len + 1);
        j = pi[j - 1];
        cout << "    Новое j = " << j << " (pi[" <<j-1 <<"])\n\n";
    }
}
if(ans.empty()){
    cout << "[РЕЗУЛЬТАТ] Подстрока не обнаружена в тексте. [-1]\n";
    return {-1};
}

return ans;
}

int main() {
    SetConsoleOutputCP(CP_UTF8);
    cout << "Введите подстроку и строку, в которой будет производиться
поиск: ";
    string P;
    string T;
    cin >> P;
    cin >> T;
    vector<int> res = KMT(P, T);
    if(res[0] != -1) {
        cout << "\n[РЕЗУЛЬТАТ] Элементы результирующего вектора: ";
        for (size_t i = 0; i < res.size(); i++) {
            if (i > 0) cout << ",";
            cout << res[i];
        }
        cout << endl;
    }
    return 0;
}

```

Название файла: KMPcycle.cpp

```

#include <iostream>
#include <string>
#include <vector>
#include <windows.h>

```

```
using namespace std;
```

```
// Функция для нахождения префикс-функции для строки Pattern (часть
алгоритма КМП)
```

```

vector<int> prefixFunc(const string &Pattern) {
    cout << " \n[ШАГ 1] Нахождение значения функции pi для строки: " <<
Pattern << endl;
    int p_len = (int)Pattern.size();
    vector<int> pi(p_len, 0); // вектор pi, который будет хранить
значения префикс-функции
    int j = 0; // длина текущего префикса, совпадающего с суффиксом
    for (int i = 1; i < p_len; ++i) {
        cout << "\n Анализ символа '" << Pattern[i] << "' (позиция " << i
<< ") в шаблоне." << endl;
        while (j > 0 && Pattern[i] != Pattern[j]) {
            cout << " Нашли различающиеся символы('" << Pattern[i]
<<"' - позиция " << i << ", '" << Pattern[j] <<"' - позиция " << j << "),
возвращаемся к предыдущему индексу.\n";
            j = pi[j - 1];
            cout << " После отката j = " << j << endl;
        }
        if (Pattern[i] == Pattern[j]) {
            cout << " Символы совпадают ('" << Pattern[i] <<"' -
позиция " << i << ", '" << Pattern[j] <<"' - позиция " << j << "),
увеличиваем индекс j (количество символов с текущем найденном
префиксе).\n";
            j++;
            cout << " j = " << j << endl;
        }
        cout << " Присваиваем значение индекса j в pi[" << i << "] =
" << j << endl;
        pi[i] = j;
    }
    cout << " \n[РЕЗУЛЬТАТ] Префикс-функция вычислена: ";
    for (int val : pi) cout << val << " ";
    cout << endl;
    return pi;
}

// Алгоритм Кнута-Морриса-Пратта
int KMPcycle(const string& Pattern, const string& Text){
    cout << "==== Алгоритм Кнута-Морриса-Пратта. =====\n";
    int t_len = (int) Text.size(), p_len = (int)Pattern.size();
    vector<int> pi = prefixFunc(Pattern);
    cout << '\n';
    int ans = -1;
    int j = 0;
    cout << "\n\n[ШАГ 2] \n";
    cout << "Продолжаем алгоритм КМП. "
        "Проходим по удвоенной длине входного текста, далее"
        " берем значение индекса по модулю длины исходного текста\n";
    for (int i = 0; i < t_len * 2; ++i) {
        cout << "\n Итерация i = " << i << ", символ в A: " << Text[i %
t_len] << endl;
        while (j > 0 && Text[i%t_len] != Pattern[j]) {
            cout << "\n Найдены отличающиеся символы в строке и
подстроке"
                "('" << Text[i%t_len] <<"' - позиция " << i%t_len <<" в
А, '" << Pattern[j] <<"' - "
                "позиция " << j << " в B), возвращаемся к индексу"
                ", который лежит в pi[" << j-1 << "]\n";
            j = pi[j - 1];
            cout << " Индекс j после отката = " << j << endl;
        }
        if (Text[i%t_len] == Pattern[j]) {
            cout << " Сравниваемые символы совпадают ('" << Text[i%t_len]
<<"' - позиция " << i%t_len <<" "

```

```

        "в A, '" << Pattern[j] <<"' - позиция " << j << " в B),
производим поиск дальше. ";
        j++;
        cout << "\n    Текущий индекс увеличился j = " << j << endl;
    }
    if (j == p_len) {
        cout << "\n    Длина текущей найденной подстроки равна длине
искомой строки,"
            "возвращаем индекс, с которого началось совпадение -
количество циклических сдвигов.\n";
        return (i - p_len + 1);
    }
}
return ans;
}

int main() {
    SetConsoleOutputCP(CP_UTF8);
    cout << "Введите две строки A и B: ";
    string A, B;
    cin >> A >> B;

    if (A.size() != B.size()){
        cout << "Строки разных размеров, A - не циклический сдвиг B: ";
        cout << -1 << endl;
        return 0;
    }
    if (A == B){
        cout << "Строки идентичны; idx = " << 0 << endl;
        return 0;
    }

    int ans = KMPcycle(B, A);

    if(ans > A.size()){
        cout << "Число в ответе больше длины исходного текста. Ошибка,
ответ - ";
        cout << -1 << endl;
        return 0;
    }

    cout << "Количество необходимых сдвигов - " << ans << endl;

    return 0;
}

```